

# Assessment of the Sustainability of Agroecosystems in the Amazon Region Using Neural Artificial Networks

J. G. D. Melo Junior, F. S. Farias and O. R. Kato

**Abstract**— The assessment of sustainability provides the actual situation of a site and provides information for decision making. In the Amazon, the assessment of the sustainability benefits of using adapted analytical models. However, this model is not always accurate. In this paper we propose a methodology that uses an artificial intelligence algorithm based on artificial neural networks (ANN), as a decision support tool, which aims to classify agroecosystems with agroforestry systems and without agroforestry systems. The sites are classified into two groups: Sustainable and Not Sustainable. For data collection we carried out technical visits to the rural community of Santa Luzia, in the municipality of Tomé-Açu, Pará Amazon. During the research data of 28 production units were collected. Finally, the data were submitted to the ANN and the results demonstrate the high potential of using computational intelligence algorithms for the purpose of monitoring the agro forestry systems in the Amazon region.

**Keywords**— Agroforestry systems, sustainability, artificial neural networks.

## I. INTRODUÇÃO

ENTENDE-SE por sustentabilidade na produção agrícola a capacidade de uma localidade manter-se produtiva de modo socioambiental ao longo do tempo dando continuidade aos processos de reprodução socioeconômica e cultural das sociedades atuais e futuras. Para avaliar atividades antrópicas, como a agricultura, desencadeou-se esforços a partir da Conferência Mundial sobre o Meio Ambiente e Conferência das Nações Unidas sobre o Meio Ambiente e Desenvolvimento, no Rio de Janeiro, em 1992, a fim de elaborar ferramentas que pudessem mensurar e monitorar como as atividades humanas são conduzidas em diferentes contextos e qual a sua relação em direção à sustentabilidade [1][2].

O processo de avaliação da sustentabilidade é uma alternativa válida para fornecer o retrato da situação da sustentabilidade de determinado local e subsidia tomadas de decisões. Dentre os inúmeros métodos utilizados para avaliar a sustentabilidade percebem-se algumas limitações quanto à complexidade no uso de indicadores e suas múltiplas

dimensões, além de dificuldades do cálculo pela subjetividade atribuída [3].

Para avaliação da qualidade ambiental, em [4], [5] e [6] os autores fizeram uso da computação como ferramenta de auxílio na tarefa de classificação de sistemas agroflorestais (SAFs). Em [4] os autores propuseram a criação de uma ferramenta de suporte a decisão que agrega informações relacionadas a fatores sociais, econômicos e biológicos. As informações são utilizadas durante a tarefa de classificação de produtividades de propriedades rurais. Enquanto que em [5] os autores propuseram um *framework* baseado em módulos que visa auxiliar os especialistas da área de engenharia florestal na realização da tarefa de planejamento de propriedades agroflorestais. No entanto, este trabalho se limitou a utilização de sub-rotinas desenvolvidas a partir do conhecimento do especialista. Finalmente, em [6] os autores propuseram a utilização de inteligência artificial como ferramenta de suporte a classificação da qualidade ambiental. Os resultados apresentam os benefícios da utilização de algoritmos de inteligência computacional como ferramenta de determinação da classificação de regiões ambientais como sustentáveis.

Já na região amazônica, processos de avaliação da sustentabilidade de agroecossistemas - aqui entendidos como local de produção agrícola sustentável equivalente a uma unidade produtiva rural individual - tem no método de avaliação MESMIS suas maiores experiências. De acordo com [7], que em 2009 estudou os limites e as potencialidades da avaliação de sustentabilidade em agroecossistemas familiares através da utilização do MESMIS na Amazônia Paraense, este é um marco de avaliação de sistemas de manejo que incorpora indicadores de sustentabilidade e tem como premissas: definir previamente um conceito local de sustentabilidade; possibilitar uma definição clara dos limites espaciais e temporais na avaliação; e representar um processo participativo e cíclico, tendo seis passos na sua operacionalização. Contudo, limita-se a necessidade de técnicos locais e informações mais precisas na coleta de dados, além da arbitrariedade do pesquisador na aplicação do modelo analítico que pode dar uma noção errada da realidade do agroecossistema.

Em virtude de não haver experiências na literatura da utilização da inteligência computacional como ferramenta de avaliação da sustentabilidade em SAFs, este artigo, ao estudar agroecossistemas que possuem SAFs em comparação com agroecossistemas que não possuem SAFs, propõe uma metodologia de avaliação da sustentabilidade de agroecossistemas na Amazônia fazendo uso de inteligência artificial, a fim de estabelecer um modelo classificador baseado em Redes Neurais Artificiais (RNA) que visa ajudar

J. G. D. Melo Júnior, Programa de Pós-Graduação em Agricultras Amazônicas - Universidade Federal do Pará (UFPA), Belém, Pará, Brasil, josejunior@ufpa.br

F. S. Farias, Professor Adjunto na Faculdade de Sistemas de Informação - Universidade Federal do Pará (UFPA), Cametá, Pará, Brasil, fabriciosf@ufpa.br

O. R. Kato, Embrapa Amazônia Oriental, Belém, Pará, Brasil, osvaldo.kato@embrapa.br

Corresponding author: Fabricio de Souza Farias.

profissionais das ciências agrárias e ambientais no processo de identificação de agroecossistemas mais sustentáveis. Por fim, este trabalho sugere uma estratégia de monitoramento baseado em visitas às unidades produtivas rurais até o alcance de índices mínimos de sustentabilidade para sistemas agrícolas.

O estudo está estruturado da seguinte forma: a seção II aborda os sistemas agroflorestais na Amazônia. A seção III apresenta o cenário em que foi realizado o estudo. A seção IV introduz os passos do *Knowledge Discovery in Databases* (KDD) aplicados neste artigo. A seção V apresenta os principais conceitos sobre RNA, principalmente o algoritmo *backpropagation*. Enquanto que a seção VI apresenta os resultados obtidos com os algoritmos analisados. Finalmente, a última seção traz as conclusões deste artigo.

## II. CONTEXTUALIZAÇÃO DO USO DE SISTEMAS AGROFLORESTAIS NA AMAZÔNIA

Sistema agroflorestal (ou simplesmente SAF) é um sistema sustentável de manejo do solo e de plantas que procura aumentar a produção de forma contínua, combinando a produção de árvores (incluindo frutíferas e outras espécies, por exemplo, madeiras) com espécies agrícolas e/ou animais, simultaneamente ou sequencialmente, na mesma área, utilizando práticas de manejo compatíveis com a cultura da população local [8].

Na Amazônia, a combinação de árvores com cultivos agrícolas deve-se a vasta experiência de pequenos e médios agricultores no município de Tomé-Açu, Estado do Pará. Os agricultores são em sua maioria descendentes de imigrantes japoneses que vêm desenvolvendo ao longo das últimas quatro décadas SAFs simultâneos e sequenciais enquanto alternativa ao monocultivo da pimenta-do-reino (*Piper nigrum*) e também ao uso de fogo na agricultura amazônica. A utilização de SAFs simultâneos e sequenciais permite a diversificação da produção e possibilita maiores ganhos econômicos em relação a somente o monocultivo, por exemplo, através da combinação da pimenta-do-reino com as culturas de cacau (*Theobroma cacao*), castanha-do-pará (*Bertholletia excelsa*), cupuaçu (*Theobroma grandiflorum*), pupunha (*Guilielma gasipaes*) e açaí (*Euterpe oleraceae*) [9][10].

Em termos de sustentabilidade, agroecossistemas com SAF tendem a processos mais sustentáveis do que aqueles agroecossistemas sem um sistema diversificado, porém essas evidências apenas podem ser comprovadas mediante uma avaliação da sustentabilidade do agroecossistema.

## III. CENÁRIO DE ESTUDO

O trabalho foi desenvolvido em unidades produtivas de agricultores familiares da comunidade rural de Santa Luzia, município de Tomé-Açu, Pará (um dos estados componentes da Amazônia Legal).

Tomé-Açu pertence à Mesorregião Nordeste Paraense e está distante 265 km da capital do Estado do Pará, Belém, e tem a atividade agrícola como uma das mais importantes fontes de geração de trabalho e renda para a sua população, onde há diversas localidades em que há o prevailecimento da agricultura de base familiar [11].

Em uma destas localidades realizou-se esta pesquisa, na comunidade de Santa Luzia, que se localiza a 40 km da sede do município de Tomé-Açu (Fig. 1) e apresenta a agricultura enquanto principal atividade de sustento das famílias ali residentes, que adotaram, em sua maioria, o SAF como alternativa de uso da terra, antes cultivada principalmente com a pimenta-do-reino [12][13].

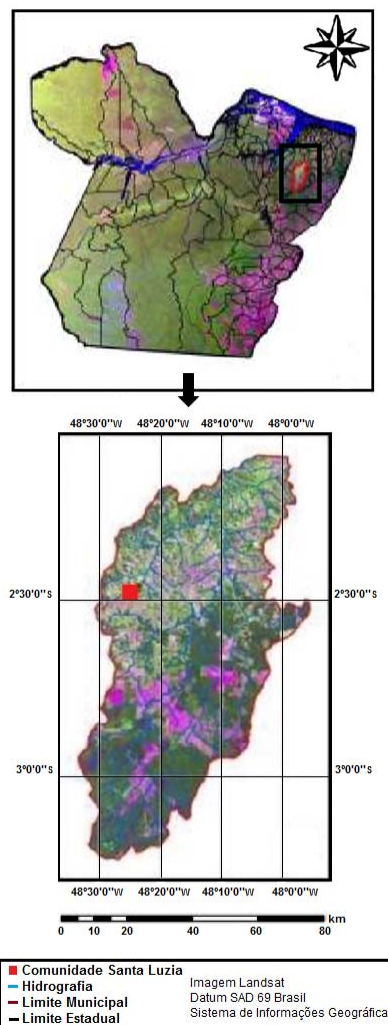


Figura 1. Localização da Comunidade rural de Santa Luzia em Tomé-Açu  
Fonte: Adaptado de Barbosa et al. (2012).

Na comunidade de Santa Luzia estudou-se 28 famílias agricultoras (18 com SAF em seus agroecossistemas e 10 sem SAF em seus agroecossistemas), e buscou-se através de métodos de inteligência computacional apontar quais agroecossistemas apresentam-se mais sustentáveis nesta comunidade. Para isso, tendo enquanto primeira etapa do estudo empírico, a aplicação de um questionário de caracterização dos agroecossistemas familiares (conforme Tabela I), que de forma participativa colheu dados sobre suas unidades de produção, além de informações do perfil sociocultural e dos aspectos técnicos e econômicos de 18 famílias agricultoras com SAF em seus agroecossistemas (escolhidas de forma intencional ao contemplar membros da Associação dos Produtores e Produtoras Rurais da Agricultura Familiar do Município de Tomé-Açu – APPRAFAMTA) em

comparação com 10 famílias agricultoras sem SAF em seus agroecossistemas (escolhidas aleatoriamente).

TABELA I  
QUESTÕES LEVANTADAS PARA CARACTERIZAÇÃO DOS  
AGROECOSSISTEMAS

Nº	Questões levantadas	Escala de avaliação		
		Baixo	Regular	Alto
1º	Manutenção da vegetação natural	Nota 0 (até 20%)	Nota 5 (21 - 50%)	Nota 10 (> 50%)
2º	Percentual de SAF implantados	Nota 0 (<10%)	Nota 5 (11 - 50%)	Nota 10 (> 50%)
3º	Nível de diversidade intra-cultivo	Nota 0 (3 espécies)	Nota 5 (até 5 espécies)	Nota 10 (> 5 espécies)
4º	Nível de diversidade de atividades produtivas	Nota 0 (SAF+pequenas criações)	Nota 5 (SAF + pequenas criações + roça anual + semiperenes)	Nota 10 (SAF+pecuária+roça anual+semiperenes+perenes+pequenas criações)
5º	Uso de insumos químicos	Nota 0 (Sim)	Nota 5 (Esporádica)	Nota 10 (Não)
6º	Uso de insumos orgânicos	Nota 0 (Não)	Nota 5 (Esporádica)	Nota 10 (Sim)
7º	Erosão visível	Nota 0 (Sim)	Nota 5 (Esporádica)	Nota 10 (Não)
8º	Escassez ou outras limitações hídricas	Nota 0 (Frequente)	Nota 5 (Raramente)	Nota 10 (Não)
9º	Situação da saúde familiar	Nota 0 (Ruim)	Nota 5 (Razoável)	Nota 10 (Boa)
10º	Situação da escolaridade familiar	Nota 0 (analfabeto até o fundamental incompleto)	Nota 5 (ensino médio)	Nota 10 (ensino superior)
11º	Participação em organizações	Nota 0 (nenhuma)	Nota 5 (Passiva)	Nota 10 (Ativa)
12º	Participação nas decisões coletivas	Nota 0 (nenhuma)	Nota 5 (Raramente)	Nota 10 (Sempre)
13º	Diálogo com equipe de ATER, agentes externos e/ou capacitação	Nota 0 (nenhuma)	Nota 5 (Esporádico)	Nota 10 (Constante)
14º	Contratação de mão de obra	Nota 0 (Sempre)	Nota 5 (Esporádica)	Nota 10 (Não)
15º	Trabalho fora do lote	Nota 0 (Sempre)	Nota 5 (Esporádica)	Nota 10 (Não)
16º	Descanso e lazer	Nota 0 (Não)	Nota 5 (Fins de semana)	Nota 10 (até férias)
17º	Capacidade de cobrir demanda de trabalho no agroecossistema	Nota 0 (Baixa)	Nota 5 (Média)	Nota 10 (Alta)
18º	Renda familiar per capita	Nota 0 (< 0,5 SM/mês)	Nota 5 (0,75-0,5 SM/mês)	Nota 10 (> 0,75 SM/mês)
19º	Importância das atividades produtivas	Nota 0 (> 0,5).	Nota 5 (0,1-0,5)	Nota 10 (0,0)
20º	Importância (dependência) da renda externa	Nota 0 (< 0,5).	Nota 5 (0,75-0,5)	Nota 10 (> 0,80)
21º	Tamanho do patrimônio familiar	Nota 0 (< 0,50).	Nota 5 (0,5-0,7)	Nota 10 (> 0,7)
22º	Dívidas contraídas	Nota 0 (>0,7)	Nota 5 (entre 0,7 e 0,5)	Nota 10 (<0,5)
23º	Rendimento físico médio	Nota 0 (Baixa).	Nota 5 (Média)	Nota 10 (Alta)
24º	Perda de rendimento físico	Nota 0 (Alta).	Nota 5 (Baixa)	Nota 10 (Nenhuma)
25º	Diversidade de atividades produtivas	Nota 0 (especializado em uma).	Nota 5 (entre 2-3)	Nota 10 (> 3)
26º	Dependência de insumos externos	Nota 0 (Total).	Nota 5 (Parcial)	Nota 10 (Nenhuma)
27º	Diversidade de linhas de crédito disponíveis	Nota 0 (Nenhuma).	Nota 5 (Baixa)	Nota 10 (Alta)
28º	Diversificação atual	Nota 0 (1 atividade).	Nota 5 (2 a 3)	Nota 10 (+ de 3)
29º	Vontade de diversificar	Nota 0 (Não).	Nota 5 (Pensa)	Nota 10 (Faz)
30º	Manutenção da diversidade natural	Nota 0 (> 50%)	Nota 5 (21 a 50%)	Nota 10 (20% desmatado ou manutenção de área de pouso)

#### IV. APLICAÇÃO DO KDD

O *Knowledge Discovery in Databases* (KDD) (vide Fig. 2) consiste em um conjunto de técnicas organizadas em etapas, que iniciam desde a criação da base de dados até a extração de conhecimento por meio da aplicação de uma técnica de inteligência computacional ou estatística no processo de mineração de dados, também conhecido como *data mining* [14].

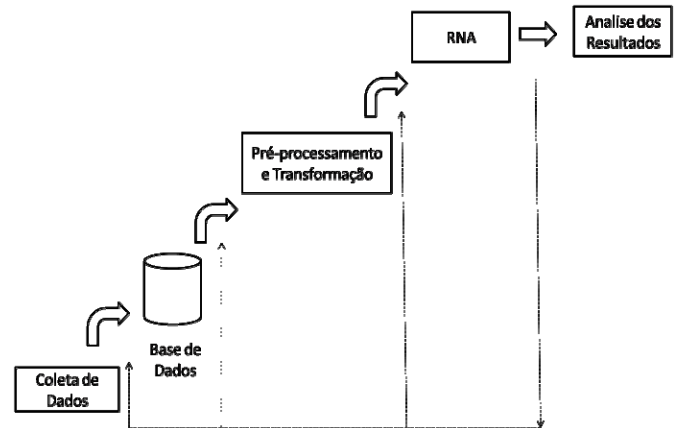


Figura 2. Fluxograma resumindo as etapas do KDD.

Na etapa de coleta dos dados para a criação de uma base de dados, foram feitas visitas e entrevistas nos 28 agroecossistemas. Durante as visitas 30 questões foram respondidas pelos agricultores e avaliadas pelo Engenheiro Florestal, José Gomes de Melo Júnior, no âmbito de sua pesquisa de mestrado, sob a orientação do Doutor Osvaldo Ryohei Kato, Pesquisador da Empresa Brasileira de Pesquisa Agropecuária (Embrapa – Amazônia Oriental) e Professor da Universidade Federal do Pará (UFPA). A Tabela II apresenta a divisão da base de dados após as entrevistas (contendo propriedades rurais classificadas pelo especialista como *Sustentável* e *Não Sustentável*) e sua representação para utilização na RNA.

Após a coleta das informações, deu-se início a etapa de pré-processamento e transformação dos dados. Nesta etapa, converteram-se as entradas literais, por exemplo: baixo, médio e alto, para valores numéricos, os quais a RNA é capaz de interpretar. A Tabela III apresenta a conversão dos resultados obtidos na entrevista por notas que variam de zero até dez. A coluna “Questões”, representada na Tabela III, separa as questões do questionário que possuem as mesmas saídas.

Após a transformação dos dados de entrada e da divisão dos registros, a base de dados foi apresentada ao algoritmo de RNA com o intuito de classificar as propriedades rurais.

Finalmente, os resultados alcançados são analisados considerando a comparação da saída do algoritmo com a saída desejada. O principal objetivo é reduzir o erro de classificação em 0%. O modelo descrito na Fig. 2 é cíclico. Desta forma, caso alguma etapa não alcance o objetivo desejado é possível retornar a uma anterior para, por exemplo, ajustar a base de dados, aplicar o pré-processamento e transformação nos dados ou até mesmo substituir o algoritmo de inteligência computacional utilizado.

TABELA II  
DIVISÃO DOS REGISTROS

Tipo de Unidade Produtiva Rural Individual	Número de Amostras	Representação na RNA
Sustentável	22	1
Não Sustentável	6	0

## V. REDES NEURAIS ARTIFICIAIS

As Redes Neurais Artificiais (RNA) são exemplos de sistemas que buscam simular o comportamento inteligente do cérebro.

A construção da RNA tem inspiração nos neurônios biológicos e nos sistemas nervosos humanos [15]. Para isso, utilizam regras de aprendizado bem estabelecidas que possam ser implantadas de diversas maneiras, através de vários algoritmos, que diferem entre si de acordo com suas capacidades e limitações.

A forma genérica para representação de uma RNA é dada por um vetor de entrada  $X$  com tamanho  $n$ , onde  $n$  representa o número máximo de entradas. O vetor de entrada é representado por:  $X = (x_1, x_2, x_3, \dots, x_n)^T$ . A partir da entrada a RNA retorna um vetor de saída com tamanho  $m$ , onde  $m$  representa o número de possíveis saídas. O vetor de saída é representado por:  $Y = (y_1, y_2, \dots, y_m)^T$ .

A RNA é tipicamente organizada em diversas camadas. A primeira camada é a chamada de camada de entrada. Nesta camada o número de nós corresponde a  $n$ , ou seja, o tamanho máximo do vetor  $X$ . A última camada é chamada de camada de saída. Nesta camada o número de nós corresponde a  $m$ , ou seja, ao tamanho máximo do vetor  $Y$ . Entre as camadas de entrada e saída existem as camadas intermediárias (chamada camada escondida). Em uma RNA pode-se existir uma ou mais camadas escondidas. As camadas escondidas são totalmente conectadas com os nós das camadas adjacentes, ou seja, camadas de entrada e saída. Entre as conexões dos nós existem os pesos sinápticos associados a cada conexão.

Para o aprendizado de uma RNA são utilizadas regras para atualização dos pesos sinápticos. O objetivo é minimizar a função erro repetindo iterativamente até que a condição de parada seja satisfeita. A função de ativação adiciona um grau de não linearidade no modelo. Neste estudo escolhemos a função de ativação *sigmoid*, ilustrada na Equação (5). Adicionalmente, é proposto a utilização de uma RNA de três camadas baseada no algoritmo *backpropagation*. Na subseção A descrevemos o algoritmo utilizado.

## A. Backpropagation

O algoritmo *backpropagation* foi desenvolvido por Werbos, em 1974 [16], e em 1982 por Parker [17]. Desde sua criação o algoritmo *backpropagation* tem sido largamente utilizado como um algoritmo de aprendizado para RNA com topologia de múltiplas camadas [6][18][19]. No entanto, é comumente utilizado com três camadas (entrada, escondida e de saída).

TABELA III  
DADOS TRANSFORMADOS PARA APLICAÇÃO NA RNA

Questões	Resposta			
	Coletada	Baixo/Pequeno	Médio/Razoável	Alto/Grande
1,2,3,4,17,18,19,21,22,23,25,28,29,30	Transformada	0	5	10
5,15	Coletada	Sim	Esporádico	Não
	Transformada	0	5	10
6,7	Coletada	Não	Esporádico/Média	Sim
	Transformada	0	5	10
8	Coletada	Frequente	Raramente	Não
	Transformada	0	5	10
9,10	Coletada	Ruim	Regular	Bom
	Transformada	0	5	10
11,12,13,16	Coletada	Nenhum	Passiva/Esporádico/Bom	Ativa/Sempre/Sempre
	Transformada	0	5	10
14	Coletada	Sempre	Esporádico	Não
	Transformada	0	5	10
20	Coletada	Grande	Razoável	Pouca
	Transformada	0	5	10
24	Coletada	Alto	Médio	Baixo
	Transformada	0	5	10
26	Coletada	Total	Parcial	Nenhum
	Transformada	0	5	10
27	Coletada	Nenhum	Baixa	Alta
	Transformada	0	5	10

Este algoritmo é baseado no método do gradiente descendente para correção do erro, por meio da propagação das entradas para cálculo das saídas (respostas do algoritmo) e retropropagação para ajuste dos pesos sinápticos (processo de aprendizagem) [20]. Desta forma, é utilizado um aprendizado através de exemplos de entrada e saída, ou seja, caso a saída encontrada seja diferente da saída desejada o ajuste dos pesos sinápticos é retropropagado através da minimização de uma função custo obtida com o uso do gradiente descendente.

O passo de propagação (*forward*) inicia pelo envio de sinais de entrada, representadas pelas respostas do formulário. Esse processo se repete até a camada de saída e o cálculo de um valor de saída é realizado. A retropropagação (*backpropagation*) calcula o erro e compara o valor calculado na saída com a saída desejada apresentada à rede. Novos conjuntos de pesos são iterativamente calculados, através da modificação dos pesos existentes, baseada nos valores de erros até um erro mínimo global ser alcançado. O Erro Médio Quadrático (EMQ) é normalmente usado como uma medição do erro global.

A estrutura básica do funcionamento do algoritmo ocorre como é descrito nas Equações (1) - (5). Primeiramente a matriz a ser treinada é normalizada na Equação (1), em seguida é multiplicada pela matriz de pesos gerados aleatoriamente e a RNA *net* é criada na Equação (2). A RNA *net* é apresentada à função de ativação do algoritmo na Equação (3). Enquanto que, na Equação (4) a saída gerada pelo treinamento está pronta para a comparação e realização do cálculo do erro da saída desejada em relação à saída encontrada. Finalmente, a função de ativação representada na Equação (5) é uma função *sigmoid*, onde  $k$  é um escalar

positivo. A função de ativação foi utilizada no problema devido ser a função mais popular e aceita na literatura.

$$x_j = \text{normaliza}(X_m) \quad 1 < d \leq m \quad (1)$$

$$\text{net}_k = \sum_{j=1}^{k-1} W_{kj} x_j \quad m \leq k \leq N + m \quad (2)$$

$$x_k = f(\text{net}_k) \quad m \leq k \leq N + m \quad (3)$$

$$o_{s-1} = x_{N+s} \quad 1 \leq s \leq n \quad (4)$$

$$f(\text{net}_k) = \frac{1}{1 + e^{-\text{net}_k}} \quad (5)$$

Na modelagem matemática a variável  $X$  representa as entradas atuais para a rede;  $X_j$  representa a entrada normalizada;  $m$  é o número de entradas para a rede;  $n$  é o número de saídas da rede neural;  $W_{kj}$  são os elementos da matriz de peso, nos quais, o tamanho depende do número de neurônios na camada adjacente correspondente da rede neural;  $N$  é o número de neurônios na rede neural, o qual é uma constante;  $O_s$  são saídas a partir da rede neural.

## VI. RESULTADOS

Nesta seção é apresentada uma descrição detalhada dos parâmetros utilizados para alimentar o algoritmo de classificação baseado na RNA, os resultados alcançados e um modelo de aplicação da RNA para auxiliar processos de identificação de agroecossistemas sustentáveis.

Durante as simulações os parâmetros de taxa de aprendizagem, número de neurônios na camada escondida, número de épocas, e base de dados de treinamento, validação e teste foram combinados e alterados durante 1000 simulações, conforme ilustrado na Tabela IV.

TABELA IV  
VARIAÇÃO DOS PARÂMETROS DE SIMULAÇÃO

Parâmetros de Simulação	Número de Amostras
Taxa de aprendizagem	0.1 - 1
Número de neurônios na camada escondida	10 - 100
Divisão da base de dados em porcentagem de Treinamento, Validação e Teste respectivamente	50, 20, 30
	60,15,15,
	70,10,10
	30,50,20
	30,20,50

Dentre as arquiteturas simuladas a mais adequada possui trinta neurônios na camada de entrada (representando as respostas normalizadas na etapa de pré-processamento e transformação para cada pergunta), vinte e cinco neurônios na camada escondida e um neurônio na camada de saída (representando as duas possíveis classes de saída – *Sustentável* (se saída igual a 1) e *Não Sustentável* (se saída igual a 0)).

A taxa de aprendizagem foi variada linearmente de 0,1 até 1. O número de neurônios na camada escondida foi variado linearmente de 10 até 100. Por último, a distribuição dos registros da base de dados seguiu os valores descritos na Tabela IV.

O melhor desempenho do algoritmo executou em 1000 épocas, e obteve seu melhor resultado na época 32 alcançando seu ótimo global e erro médio absoluto de 0.00053. Durante cada simulação foram calculados os EMQ e a taxa de registros classificados de forma incorreta (*misclassified*) em porcentagem (E%) para cada uma das três etapas, conforme descrito na Tabela V. Note que no melhor caso as etapas de treinamento, validação e teste alcançaram uma taxa de registros *misclassified* igual a 0%.

A Fig. 3 apresenta graficamente o EMQ para treino, validação e teste em todas as épocas percorridas pelo algoritmo. A porcentagem de exatidão alcançada pela RNA após as etapas de Treinamento, Validação e Teste foi de 100%.

TABELA V  
RESULTADOS ALCANÇADOS PELA RNA

Etapas	Nº de Registros	EMQ	E%
Treinamento	20	8.99.10-8	0
Validação	4	5.34.10-4	0
Teste	4	1.32.10-7	0




Figura 3: Representação gráfica dos resultados obtidos por época.

A Fig. 4 apresenta o fluxograma de como a RNA pode ser uma ferramenta de auxílio aos profissionais na identificação de agroecossistemas mais sustentáveis. Mediante a aplicação do questionário, descrito na seção III, o pesquisador terá um conjunto de notas representando a situação atual do agroecossistema. As notas serão a entrada para a RNA, a qual irá identificar o agroecossistema como *Sustentável* ou *Não Sustentável*. Caso o agroecossistema seja classificado como *Não Sustentável* o profissional irá utilizar a sua expertise para sugerir que a unidade produtiva se adeque a padrões de sustentabilidade estipulados. Após um período de adaptação (inferido pelo especialista durante a pesquisa), no qual o proprietário deverá realizar ações sugeridas pelo especialista, aplicar-se-á novamente um questionário para caracterização do agroecossistema. Em seguida as respostas serão adicionadas como entrada da RNA. Desta vez, caso a propriedade seja classificada como *Sustentável*, o profissional verificará se houve um aumento do nível de sustentabilidade



no agroecossistema, caso a resposta seja negativa, a propriedade rural sofrerá ajustes para alcançar os níveis de sustentabilidade adequados. Caso contrário, o profissional irá por meio de sua expertise sugerir novas melhorias que deverão ser aplicadas em um tempo estipulado (tempo de adaptação). Após o período, o profissional deverá novamente aplicar um questionário de caracterização de agroecossistemas e utilizar os resultados como parâmetros de entrada para a RNA. Caso as respostas apontem melhorias nos níveis de sustentabilidade, o agroecossistema é entendido como adequado aos padrões de sustentabilidade adotado.

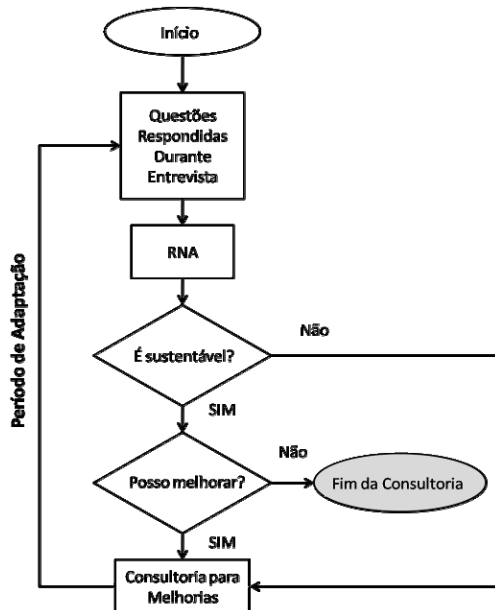


Figura 4. Representação da aplicação da RNA como ferramenta de suporte à verificação do nível de sustentabilidade de propriedades rurais.

## VII. CONCLUSÃO

Este trabalho apresentou a utilização de uma ferramenta de suporte a decisões, baseada em redes neurais artificiais, que auxiliam profissionais das ciências agrárias e ambientais no processo de identificação de propriedades *Sustentáveis* e *Não Sustentáveis*. Os resultados demonstram o elevado potencial da utilização de algoritmos de inteligência computacional com o propósito de monitoramento de agroecossistemas para: manutenção da sustentabilidade e para auxiliar unidades produtivas do tipo *Não Sustentável* a alcançar padrões mínimos de sustentabilidade estipulados.

Com base nos resultados alcançados, conclui-se que a proposta pode ser atrativa para órgãos com atuação em áreas rurais e também para empresas de consultoria, além de entidades de agricultores, pois este tipo de metodologia auxilia no processo de desenvolvimento sustentável de agroecossistemas apontando em quais âmbitos o produtor rural deve melhorar a sua unidade produtiva para alcançar níveis de sustentabilidade. Além disso, esta estratégia pode ser utilizada e expandida para outras localidades da Amazônia e de outras regiões do Brasil, assim permitindo que profissionais das ciências agrárias e ambientais auxiliem agricultores durante os processos de tomada de decisão

através da avaliação da sustentabilidade, rumo à agroecossistemas mais sustentáveis.

O algoritmo de inteligência computacional baseado em redes neurais artificiais obteve 100% de acerto na época 32 de 1000. Desta forma, confirmando a eficácia da RNA com resultado alcançado de 100% de acerto nas etapas de treinamento, validação e teste, este resultado abre novas possibilidades para a utilização da computação, principalmente inteligência computacional, na automatização de diversas soluções para problemas da área agroambiental, os quais são sobretudo, atualmente, resolvidos de forma analítica.

Em trabalhos futuros espera-se aplicar o modelo em unidades produtivas, dispostas, em outras regiões/cidades da Amazônia e do Brasil. Assim, minimizando investimentos e esforços para determinação da sustentabilidade.

## AGRADECIMENTOS

Os autores agradecem a CAPES, CNPQ e ao PPGAA-UFGA pelo apoio e suporte financeiro.

## REFERÊNCIAS

- [1] H. D. B. Passos, "Indicadores de sustentabilidade: uma discussão teórico-metodológica aplicada a sistemas agroflorestais no Sul da Bahia," Dissertação de Mestrado, Universidade Estadual de Santa Cruz, Santa Cruz, Bahia, Brasil, 2008.
- [2] H. M. V. Bellen, "Indicadores de desenvolvimento sustentável. Em: Indicadores de Sustentabilidade: uma análise comparativa," 2. Edição, Rio de Janeiro: Editora FGV, pp. 41-62, 2006.
- [3] M. M. S. Maior, G. A. Cândido, M. M. Nobrega and M. T. M. Figueiredo, "Estudo comparativo entre métodos de avaliação da sustentabilidade para unidades produtivas agroecológicas," em *anais do Encontro Nacional da Associação Nacional de Pós-Graduação e Pesquisa em Ambiente e Sociedade*, Belém, Brasil, 2012.
- [4] E. A. Ellis, G. Bentrup and M. M. Schoeneberger, "Computer-based tools for decision support in agroforestry: Current state and future needs," in *Agroforestry Systems journal*, vol. 61, no. 1, pp. 401-421.
- [5] R. I. Muetzelfeldt, "A framework for a modular modelling approach for agroforestry," in *Agroforestry Systems journal*, vol. 30, no. 1, pp. 223-234.
- [6] L. Yijun, T. Jiali, J. Hongfen, Z. Guangping and Y. Zhimin, "Artificial neural networks applied in environmental quality assessment," in *3rd IEEE International Conference on Computer Science and Information Technology (ICCSIT)*, pp. 546-549, Chengdu, 2010.
- [7] L. M. S. Silva, "Limites e potencialidades da avaliação de sustentabilidade em agroecossistemas familiares: o uso do MESMIS na porção sudeste do estado do Pará – Amazônia Brasileira," em *III Congresso Latinoamericano de Agroecología*, Oaxtepec, México, 2011.
- [8] J. G. Farrell and M. Altieri, "Sistemas Agroflorestais," *Agroecologia: bases científicas para uma agricultura sustentável*. 3. Edição, São Paulo: Expressão Popular, pp. 281-304, 2012.
- [9] J. C. L. Dubois, "Manual Agroflorestal para a Amazônia," vol. 1, Rio de Janeiro: REBRAP, 1996.
- [10] O. R. Kato, M. do S. A. Kato, C. J. R. de Carvalho, R. de O. Figueiredo, A. Camarão, T. D. de A. Sá, M. Denich and K. Vielhauer, "Uso de Agroflorestas no Manejo de Florestas Secundárias," em *Sistemas Agroflorestais – Bases Científicas para o Desenvolvimento Sustentável*, Campos dos Goytacazes: Universidade Estadual do Norte Fluminense Darcy Ribeiro, p. 119-138, 2006.
- [11] D. A. C. Frazão, A. K. O. Homma, Y. Ishisuka, A. J. E. A. de Menezes, G. B. de Matos and A. C. P. N. da Rocha, "Indicadores tecnológicos, econômicos e sociais em comunidades de pequenos agricultores de Tomé-Açu, Pará. Embrapa Amazônia Oriental," Documentos (Circular Técnica, 229), dez. 2005.
- [12] M. S. Barbosa, F. N. L. da Silva, L. R. de Medeiros, Z. R. da Poça and A. A. dos Reis, "Sistemas agroflorestais como estratégia de desenvolvimento rural sustentável da pequena produção familiar no

- município de Tomé-açu/PA,” *em anais do Congresso Norte Nordeste de Pesquisa e Inovação*, Palmas, 2012.
- [13] M. C. M. Couto, “Beneficiamento e comercialização dos produtos dos sistemas agroflorestais na Amazônia, Comunidade Santa Luzia, Tomé-Açu, Pará,” Dissertação de Mestrado, Universidade Federal do Pará, Belém, 2013.
- [14] U. Fayyad, G. P. Shapiro and P. Smyth, “From Data Mining to Knowledge Discovery in Databases,” in *Artificial Intelligence Magazine*, American Association for Artificial Intelligence, 1996.
- [15] F. M. Azevedo, “Uma proposta de modelos formais de neurônios e redes neurais artificiais,” *em anais do Congresso Brasileiro de Redes*, Florianópolis, 1997.
- [16] P. Werbos, “Beyond Regression: New Tools for Prediction and Analysis,” Ph.D. Thesis in the Behavioral Sciences, Harvard University, Cambridge, 1974.
- [17] D. Parker, “Learning Logic. Intention Report,” Stanford University, File 1, Office of Technology Licensing, p. S81-64, Stanford, 1982.
- [18] C. Francisco do Nascimento, A. Albano de Oliveira, A. Goedtel, I. Nunes da Silva and P. Jose Amaral Serni, “Neural Network-Based Approach for Identification of the Harmonic Content of a Nonlinear Load in a Single-Phase System,” in *IEEE Latin America Transactions*, vol. 8, no. 1, pp. 65-73, March 2010.
- [19] H. M. Campos Ribeiro, A. d. C. Almeida, B. R. P. D. Rocha and A. V. Krusche, “Water Quality Monitoring in Large Reservoirs Using Remote Sensing and Neural Networks,” in *IEEE Latin America Transactions*, vol. 6, no. 5, pp. 419-423, Sept. 2008.
- [20] HAYKIN, S. *Redes Neurais: Princípios e Prática*. 2. Edição. Porto Alegre: Bookman, 2002.



**José Gomes de Melo Júnior**, Engenheiro Florestal, Especialista em Educação do Campo, Agroecologia e Questão Agrária na Amazônia, Mestre em Agriculturas Familiares e Desenvolvimento Sustentável - Programa de Pós-Graduação em Agriculturas Amazônicas/Universidade Federal do Pará (UFPA), Belém, Pará, Brasil.



**Fabricio de Souza Farias** é professor adjunto vinculado à Faculdade de Sistemas de Informação da Universidade Federal do Pará (UFPA) – Campus Cametá. É engenheiro da Computação e tem mestrado e doutorado em engenharia elétrica pela UFPA. Suas áreas de pesquisa são computação aplicada a telecomunicações, inteligência artificial, mineração de dados, fundamentos de computação e engenharia de software.



**Osvaldo Ryohei Kato**, Mestre em Agronomia (Fitotecnia) e Doutor em Agricultura Tropical. É Pesquisador A da Empresa Brasileira de Pesquisa Agropecuária (Embrapa - Amazônia Oriental) e Docente no Programa de Pós-Graduação em Agriculturas Amazônicas - Universidade Federal do Pará (UFPA), Belém, Pará, Brasil.